TP1 – Initiation au traitement de données Big Data avec PySpark

1.Contexte

- Le Big Data nécessite des outils capables de traiter de grandes quantités de données rapidement. Les plateformes Cloud offrent ce type de traitement distribué.
-
- Ce TP a pour objectif de simuler un mini-environnement Cloud Big Data en utilisant **Python et PySpark** sur Google Colab, afin de comprendre les principes fondamentaux du traitement distribué et du stockage de données.

2. Objectifs

- Créer et configurer un environnement de traitement Big Data sur Google Colab.
- Charger et explorer un jeu de données avec PySpark.
- Effectuer des transformations et filtrages sur des données.
- Exporter les résultats pour simuler un stockage Cloud.

3. Étapes pratiques du TP

Partie 1 – Installer et configurer PySpark

- Installer PySpark : !pip install pyspark
- Créer une session Spark.
- Vérifier que la session fonctionne.

Partie 2 – Préparer un jeu de données

- Créer un fichier CSV 'cities.csv' avec colonnes id, city, temperature.
- Ajouter au moins 5 lignes.
- Charger ce CSV dans un DataFrame PySpark.
- Afficher les premières lignes.

Partie 3 – Exploration des données

- Afficher le schéma du DataFrame.
- Compter le nombre de lignes.
- Afficher les noms des colonnes.

Partie 4 – Traitement des données

- Calculer la température moyenne.
- Filtrer les villes avec température > 22.
- Trier les villes par température décroissante.
- Astuce : utiliser filter(), groupBy().avg(), orderBy().

Partie 5 – Sauvegarde des résultats
- Sauvegarder le DataFrame filtré dans /content/results.
- Sauvegarder sur Google Drive.

P**artie 6 – Analyse de l'environnement**
- Afficher des informations sur l'environnement Colab : nom machine, OS, version Python.

<u>Travail à rendre</u>

- Notebook .ipynb avec l'implémentation de code correspondant.
- Résultats de chaque étape.
- Commentaires expliquant chaque opération.