Large Language Models



Chapitre 1: Introduction aux LLM

Enseignante: Dr. Kaouther Ezzameli

Kaouther.zammali@islaib.u-jendouba.tn

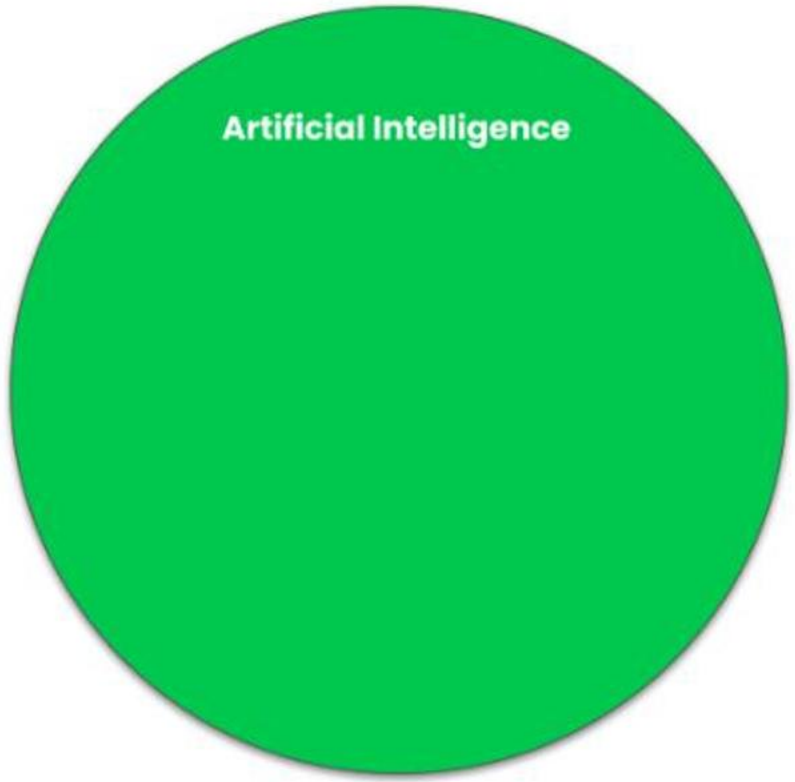
Classes: 2ème Mastère Data science

2ème Mastère IoT

A.U. : 2026-2027

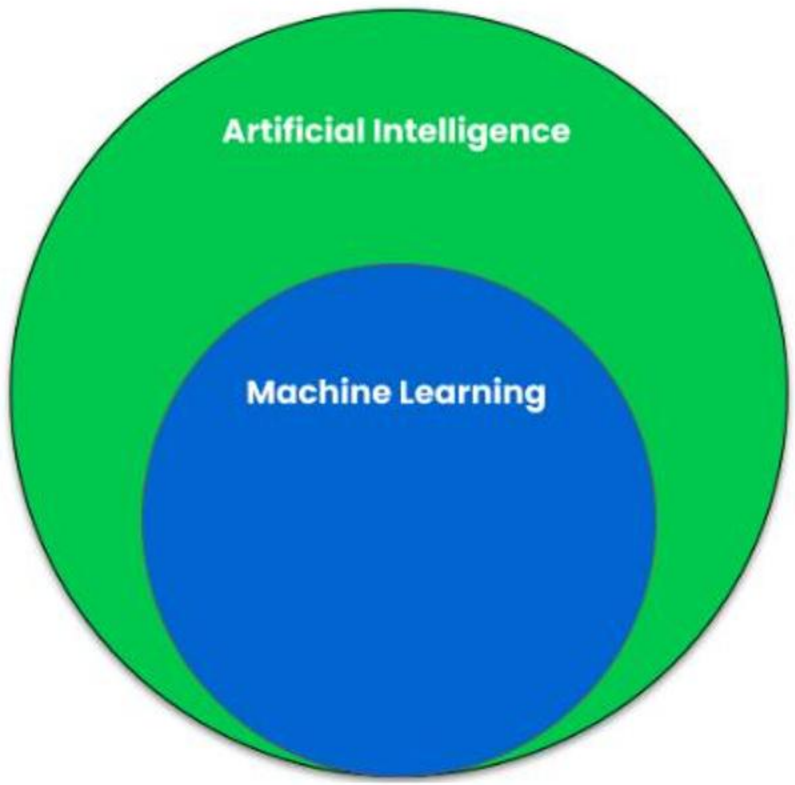
Landscape

- L'intelligence artificielle est un champ large qui fait référence à l'utilisation de technologies pour créer des machines et des ordinateurs capables d'imiter des fonctions cognitives associées à l'intelligence humaine, telles que la capacité à visualiser et comprendre le langage parlé ou écrit et y répondre, analyser les données, proposer des recommandations, etc



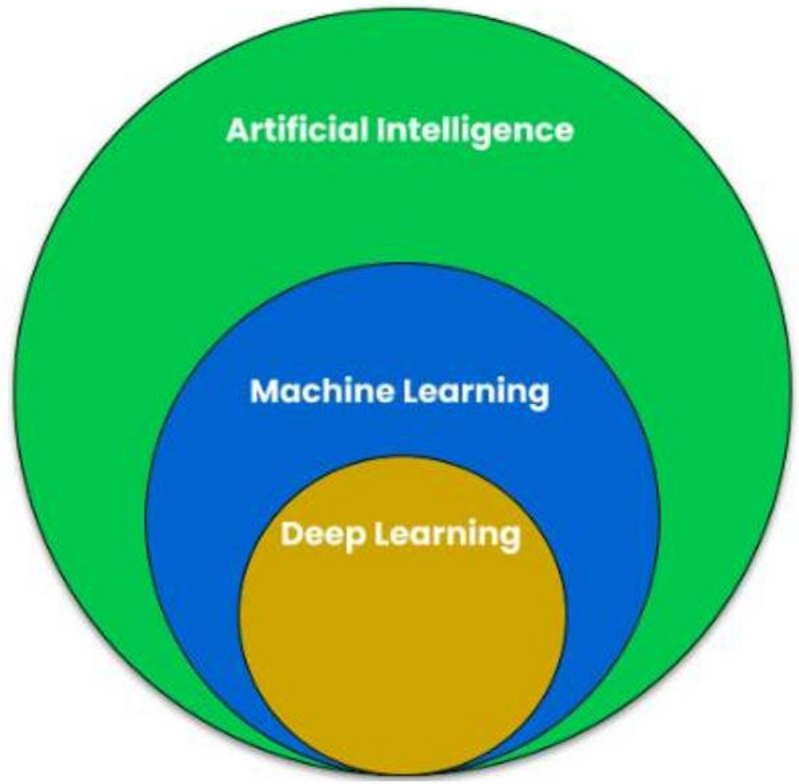
Landscape

- Machine learning: sous-domaine de l'IA qui permet à une machine ou à un système d'apprendre et de s'améliorer automatiquement grâce à l'expérience



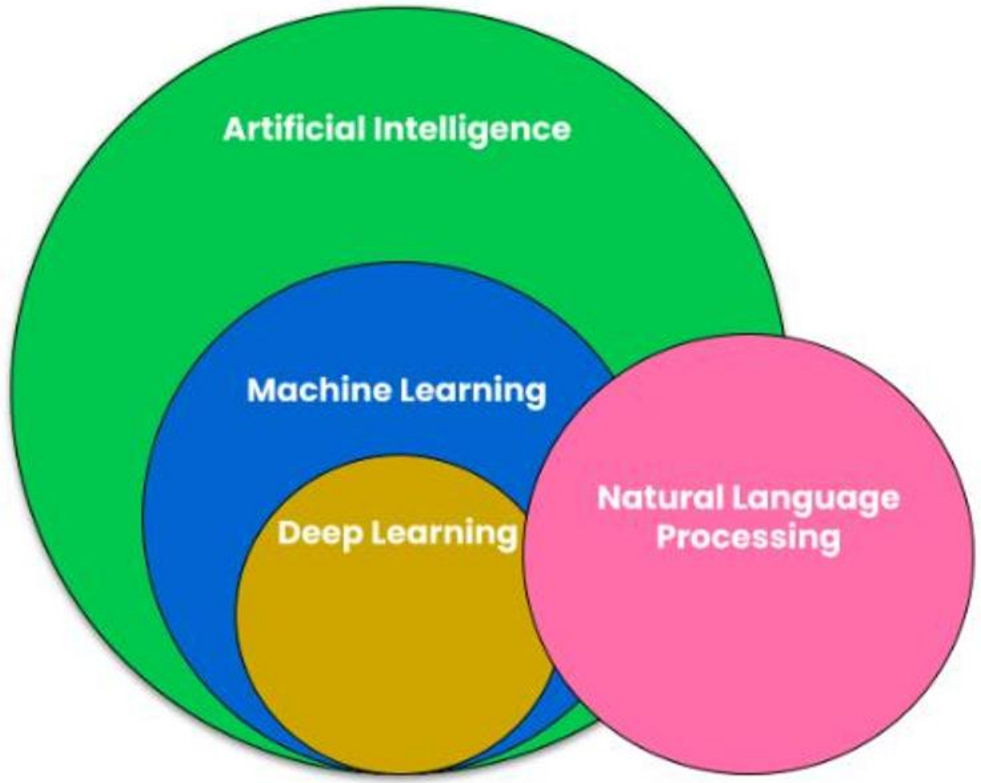
Landscape

- Le deep learning (apprentissage profond) est un sous-ensemble du machine learning (apprentissage automatique) qui utilise des réseaux de neurones artificiels multicouches pour imiter le cerveau humain



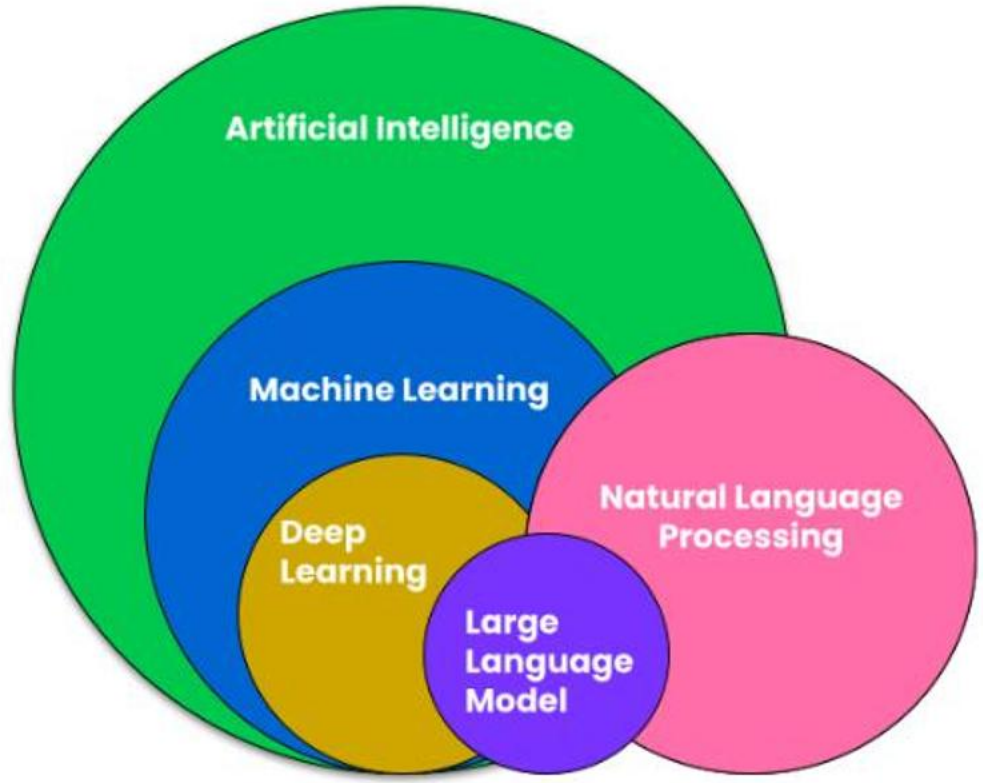
Landscape

- Le traitement automatique du langage naturel (NLP) est une branche de l'intelligence artificielle qui utilise l'apprentissage automatique pour permettre aux ordinateurs de comprendre, d'analyser et de générer le langage humain



Landscape

- LLMs: Large Language Models (Grand modèles de langage) utilisent les techniques de deep learning pour effectuer diverses tâches de traitement du langage naturel (NLP), telles que la classification de textes, le résumé, la génération, et bien plus encore.
- Les LLM sont qualifiés de « grands/massifs » (ou « larges ») car ils nécessitent une grande quantité de ressources pour fonctionner.

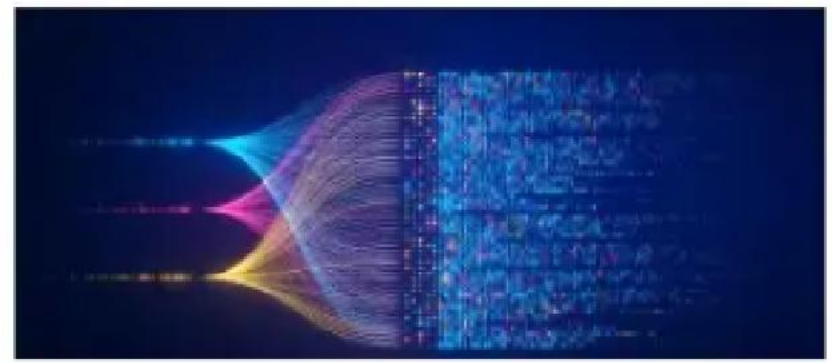


Landscape

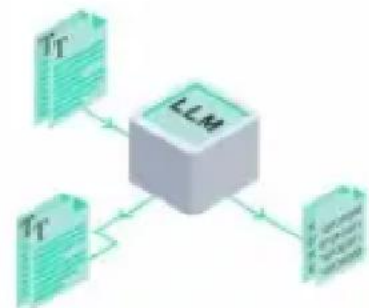
- Un **LLM (Large Language Model)** est un programme qui prédit le mot suivant dans une phrase, entraîné sur des milliards de textes. Cette capacité simple, répétée à grande échelle, permet de générer du texte cohérent, répondre à des questions, résumer des documents ou écrire du code.

Landscape

LLM (Large Language Model) ou modèle de langage à grande échelle est un type d'intelligence artificielle (IA) entraîné sur d'énormes quantités de données textuelles pour comprendre, générer et manipuler le langage humain. Ils utilisent des modèles d'apprentissage automatique sophistiqués, comme les réseaux neuronaux de type transformer, pour reconnaître des schémas, prédire le texte suivant, traduire, résumer, et bien plus encore.
est un modèle de langage possédant un grand nombre de paramètres.



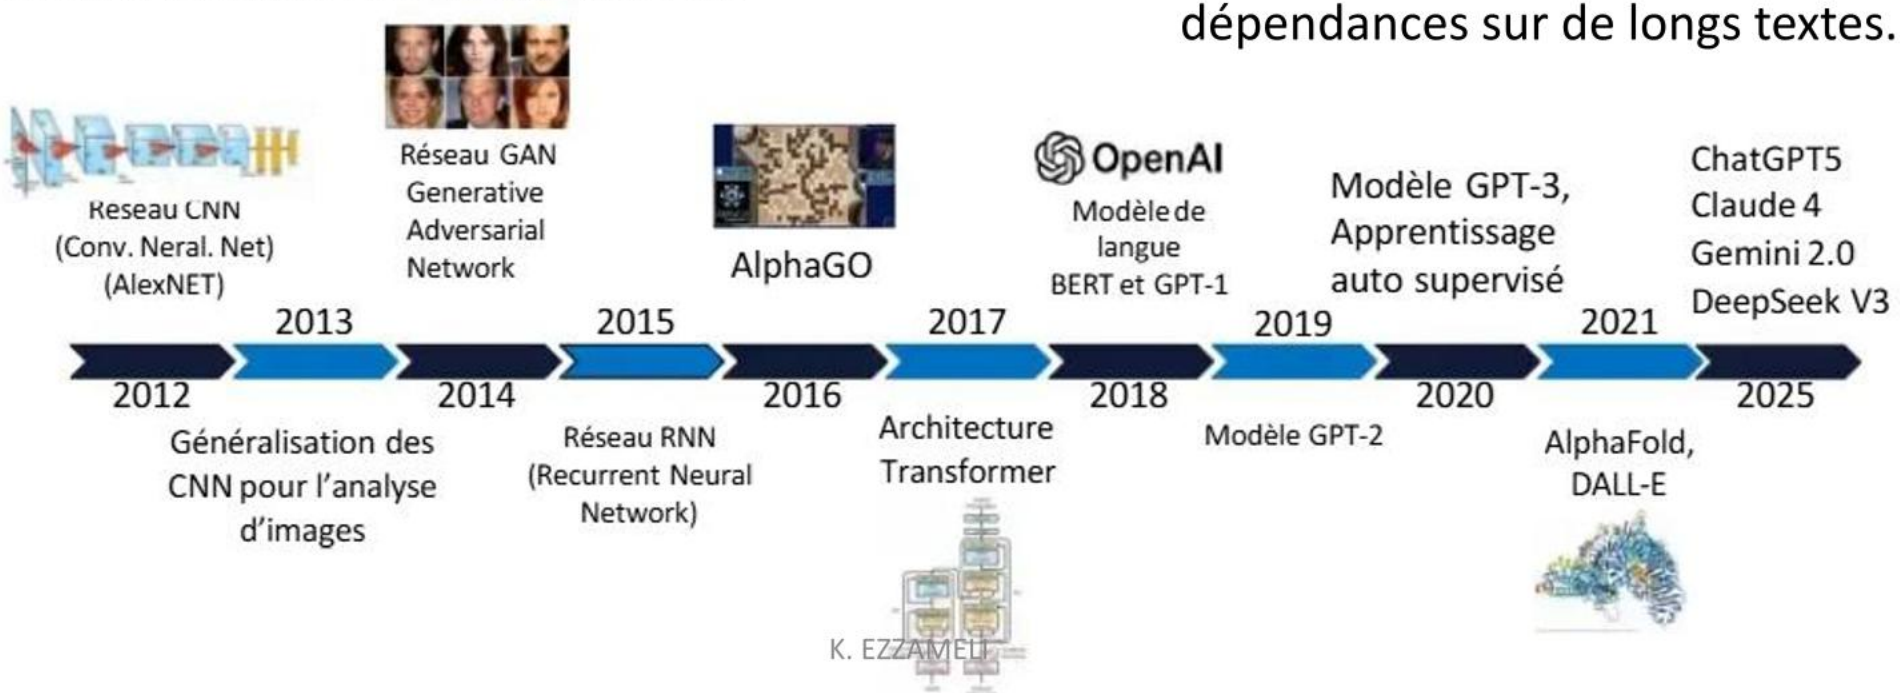
- ✓ Quelles tâches peut-il réaliser ?
  - ✓ Génération de texte
  - ✓ Traduction automatique
  - ✓ Résumé de texte
  - ✓ Répondre à des questions (agent conversationnel ou Chat Bot)
  - ✓ Classification de texte
  - ✓ Analyse des sentiments
  - ✓ Aide à la programmation



Evolution

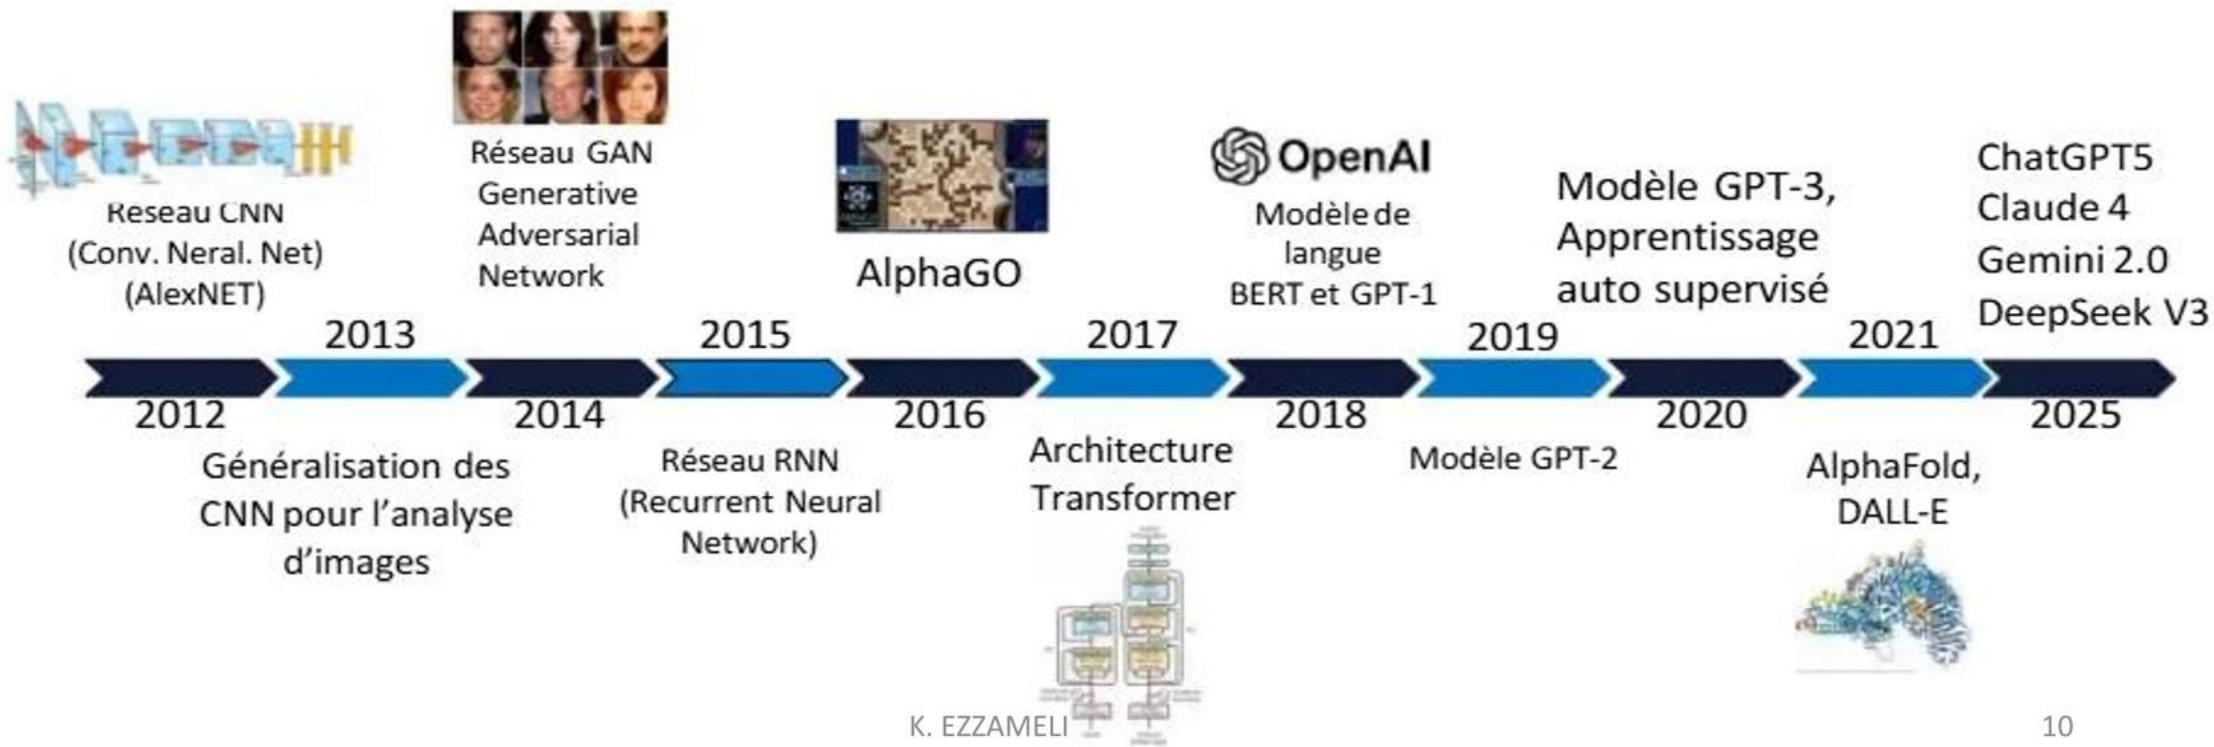
- Entre les années 1950 et 1990, les approches étaient **statistiques**. Les ordinateurs essayaient de prédire le mot suivant en se basant uniquement sur les 2 ou 3 mots précédents (les "n-grammes"). C'était très limité : les modèles n'avaient aucune compréhension réelle du sens de la phrase

Dans les années 2000, les **réseaux de neurones** ont apporté une première révolution. Des modèles comme les **RNN (Réseaux de Neurones Récurrents)** et plus tard les **LSTM** sont devenus capables de traiter des phrases entières et de mieux conserver le contexte. Cependant, ils restaient lents et peinaient à gérer les dépendances sur de longs textes.



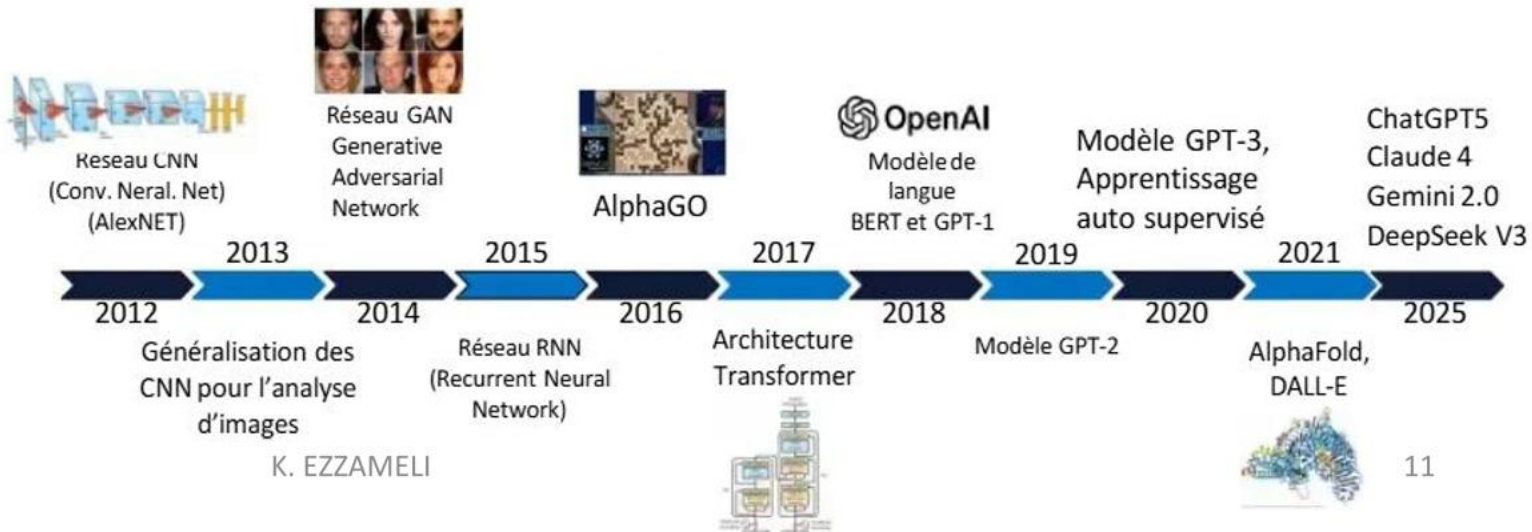
Evolution

- Le véritable tournant a eu lieu en 2017 avec l'invention de l'architecture **Transformer** par Google. Au lieu de lire le texte mot par mot, le Transformer pouvait analyser tous les mots d'une phrase en même temps grâce au **mécanisme d'attention**. Cette innovation a permis de traiter des quantités de texte beaucoup plus importantes et de comprendre des relations complexes entre les mots, même très éloignés les uns des autres.

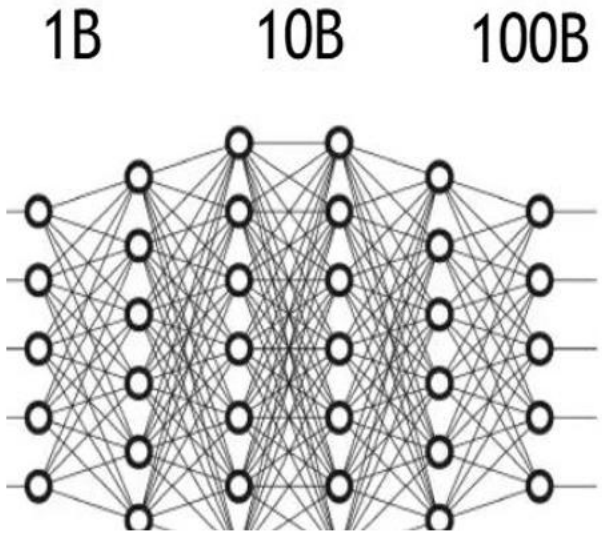


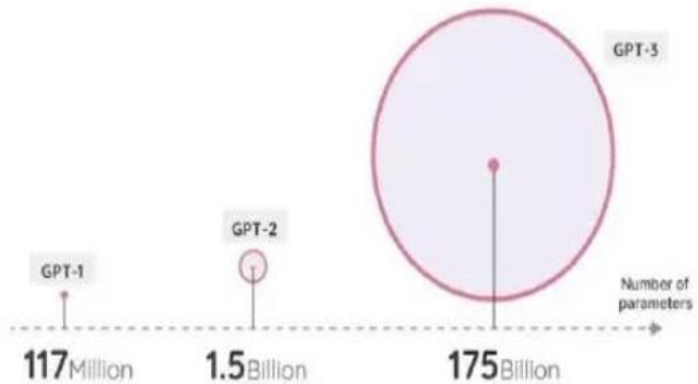
Evolution

- Cette architecture est la base de tous les **LLM** modernes. Elle a ouvert la voie à une course à la taille et à la performance, avec des modèles comme **GPT** de OpenAI, qui sont passés de quelques milliards à plusieurs centaines de milliards de paramètres en quelques années seulement.
- Trois facteurs expliquent cette explosion récente :
  - L'**architecture Transformer**, beaucoup plus efficace.
  - L'accès à des **quantités massives de données** (une grande partie d'Internet).
  - L'augmentation de la **puissance de calcul** (notamment grâce aux GPU).
- Cette combinaison a permis l'émergence de **capacités émergentes** : des compétences complexes que même leurs créateurs n'avaient pas prévues.



Paramètres d’un modèle





Modèle	Nombre de paramètres
GPT-2	1,5 milliard
GPT-3	175 milliards
GPT-4	≈ 1 000 milliards (estimation)
LLaMA-2-7B	7 milliards
Mistral-7B	7 milliards
TinyLLM (expérimental)	50 millions

Paramètres d'un modèle

Facteur	Impact sur le coût
Taille du modèle (nombre de paramètres)	Plus un modèle a de paramètres, plus il faut de calcul, de mémoire et de temps.
Données d'entraînement (nombre de tokens, volume, qualité, filtrage)	Collecter, nettoyer et gérer des données massives n'est pas gratuit.
Infrastructure matérielle	GPUs / TPUs haut de gamme, mémoire, stockage rapide, réseau — tout cela coûte cher.
Durée d'entraînement	Le temps prolongé multiplie les coûts énergétiques et opérationnels.
Optimisation algorithmique	Techniques comme mixed precision, pipeline de parallélisme, quantization pendant la formation réduisent les coûts.
Efficacité logicielle / engineering	Une mauvaise configuration, des goulots, ou un gaspillage de ressources peuvent fortement augmenter le coût.
Main-d'œuvre, recherche & développement, surveillance, debugging	Le coût humain derrière le projet (ingénieurs, chercheurs) est souvent non négligeable.
Coûts énergétiques / électricité	La consommation d'énergie pour alimenter les machines est significative sur des entraînements longs.
Coûts de stockage & I/O	Sauvegarde de checkpoints, lecture/écriture de grandes quantités de données.

Modélisation du langage

- Fondamentalement, la modélisation du langage consiste à prédire le mot suivant (ou, plus techniquement, le « jeton » ou *token* suivant) dans une séquence, en se basant sur les mots qui précèdent.
- Plus formellement, un modèle de langage apprend à attribuer un score de probabilité à une séquence de mots.
- Il quantifie la probabilité d'une séquence ou d'une suite donnée en s'appuyant sur les schémas observés au sein de la vaste quantité de données textuelles utilisées pour son entraînement.
- Comprendre la structure statistique et la probabilité des combinaisons de mots est essentiel pour permettre aux machines de :
  - Comprendre le langage : savoir que « the sky is blue» est plus probable que « the sky is elephant» aide un modèle à traiter correctement les données d'entrée.
  - Générer du langage : en prédisant de manière répétée le mot suivant le plus probable, les modèles peuvent construire des phrases et des paragraphes cohérents.
- En substance, un modèle de langage apprend la grammaire, la sémantique et le contexte d'une langue en déterminant quels mots ont tendance à en suivre d'autres.
- Cette tâche de prédiction, apparemment simple, constitue le fondement sur lequel reposent la quasi-totalité des capacités avancées de NLP : de la traduction automatique et de la reconnaissance vocale jusqu'aux conversations complexes que nous entretenons avec des assistants d'IA modernes comme Gemini ou GPT-4.

De N-grams aux Transformers

1. N-Gram Models (1948–1990s): Language as Probabilities

- Les modèles de n-grammes prédisent le mot suivant en se basant sur les (n−1) mots précédents. Par exemple, un modèle de trigrammes utilise les deux mots précédents pour deviner le troisième :
- « I want to eat a slice of ___ »

→ Peu de chances de deviner « cake » à moins que cette phrase exacte ne soit apparue lors de l'entraînement.

- Un **n-gramme** est tout simplement une **séquence contiguë** de n éléments extraite d'un texte. Ces éléments peuvent être des **caractères**, des **syllabes**, des **mots** ou même des **phrases** entières.
- Découpage d'un texte en petits morceaux de taille identique. Chacun de ces morceaux constitue un n-gramme. Par exemple, dans la phrase "J'aime le marketing digital" :
- Les **unigrammes** (n=1) sont : "J'aime", "le", "marketing", "digital"
- Les **bigrammes** (n=2) sont : "J'aime le", "le marketing", "marketing digital"
- Les **trigrammes** (n=3) seraient : "J'aime le marketing", "le marketing digital"
- Cette approche permet d'analyser la **structure linguistique** d'un texte sans nécessiter une compréhension sémantique profonde.

E.g., "thank you very much" → "for coming"

De N-grams aux Transformers

1. N-Gram Models (1948–1990s): Language as Probabilities

Avantages :

- Simple et rapide
- Efficace pour les phrases courtes et fréquentes

E.g., "thank you very much" → "for coming"

Inconvénients:

- Absence de notion de sens : les mots sont traités comme des symboles isolés ; il n'y a aucune notion de similarité entre « chien » et « chiot ».
- Rareté des données : les combinaisons rares ou inédites ne peuvent pas être prédites.
- Fenêtre de contexte rigide : incapacité à gérer les dépendances à longue distance ou les variations.

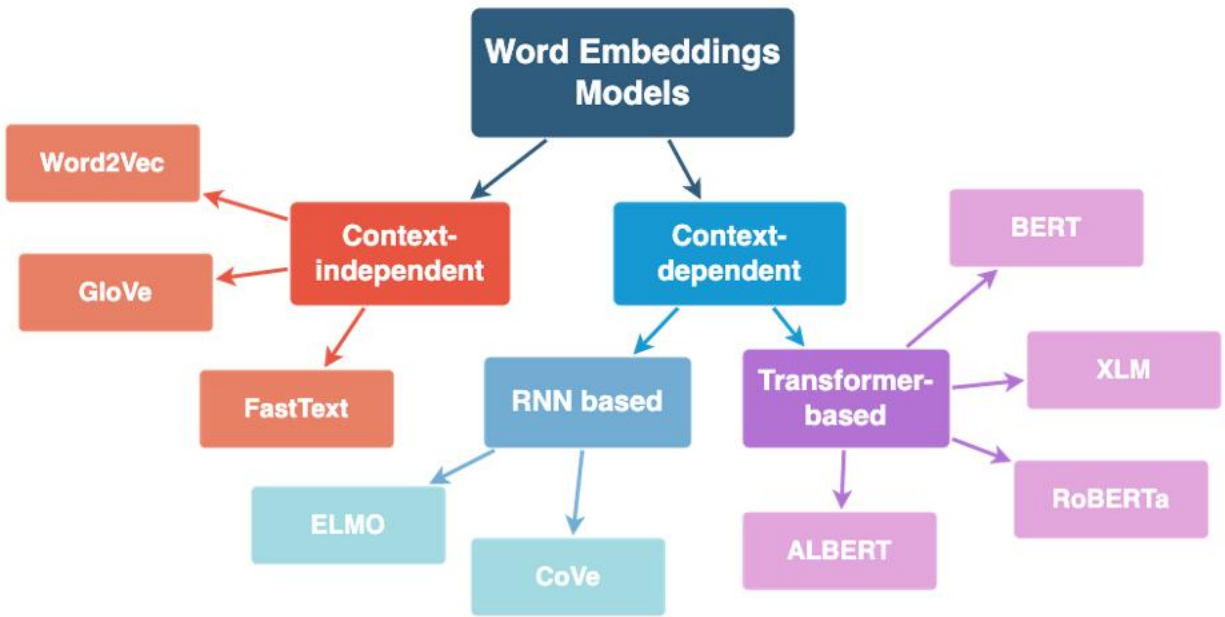
Transition → Cela a mis en évidence un défi majeur : le langage ne se résume pas à des séquences ; il repose sur le sens et la mémoire.

De N-grams aux Transformers

2. Neural Language Models & Word Embeddings (2013–2015): Capturing Meaning

- Les modèles neuronaux ont introduit le concept de plongements de mots (*word embeddings*) — des vecteurs qui encodent des relations sémantiques. Ces plongements sont appris via :

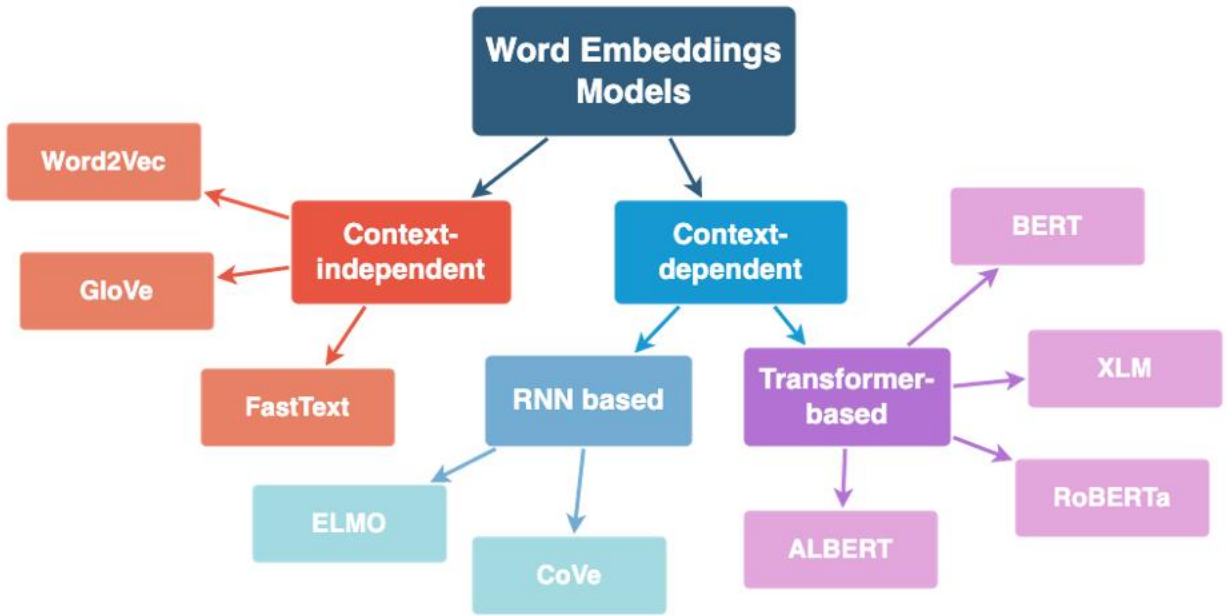
- Word2Vec (CBOW et Skip-gram) : prédire un mot à partir de son contexte ou inversement.
- GloVe : factoriser une matrice de cooccurrence de mots.
- « Roi — Homme + Femme = Reine »
- « Paris — France + Italie = Rome »



De N-grams aux Transformers

2. Neural Language Models & Word Embeddings (2013–2015): Capturing Meaning

- Les mots ayant des significations similaires possèdent des représentations vectorielles proches.
- Ils permettent de capturer les analogies, les relations et les regroupements sémantiques dans un espace continu.
- Ces modèles ont atténué le problème de la sparsité des données, rendant possible la généralisation à des groupes de mots similaires.



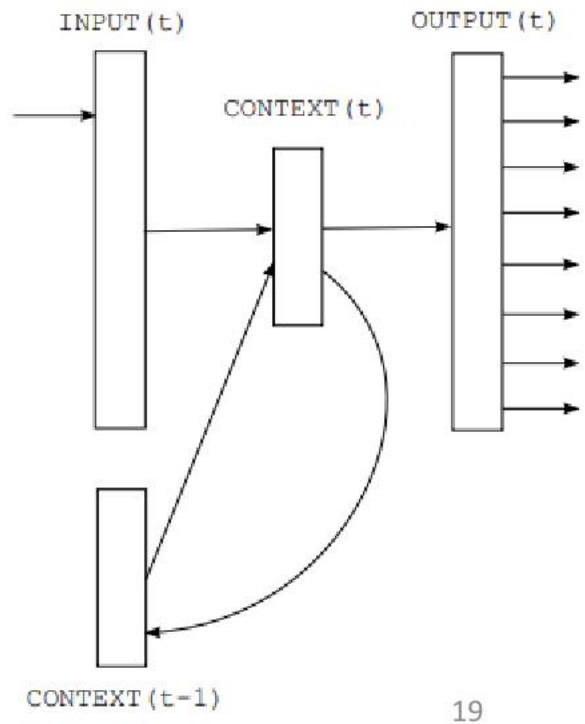
Transition → Si les plongements lexicaux (*embeddings*) permettaient de saisir le sens, ils ne pouvaient ni comprendre l'ordre des mots ni mémoriser le contexte précédent ; c'est là que les RNN sont intervenus.

Pour appréhender les séquences et le contexte, nous nous tournons vers les réseaux de neurones récurrents (RNN).

De N-grams aux Transformers

3. RNNs & LSTMs (2014–2016): Memory Enters the Picture

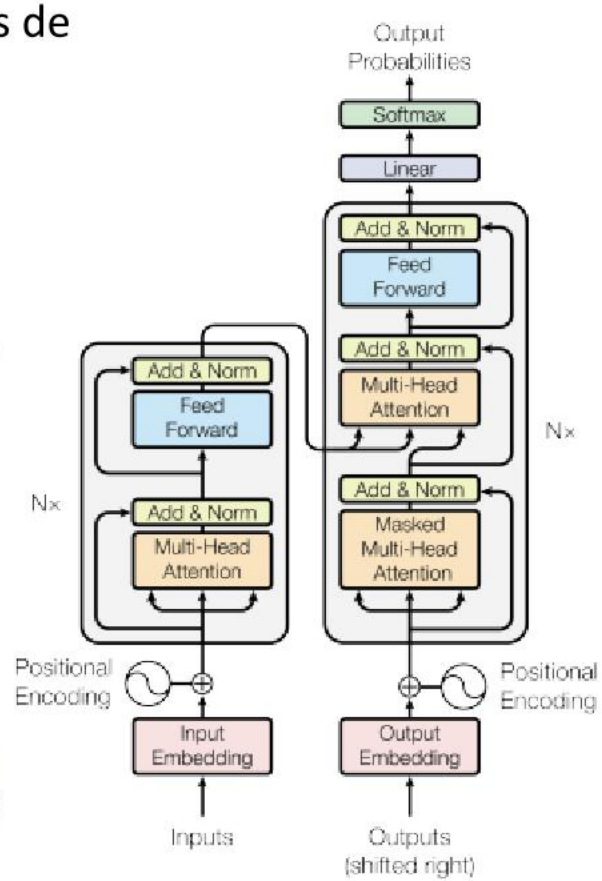
- Les réseaux de neurones récurrents (RNN) traitent les séquences mot à mot, en préservant des informations au fil des étapes temporelles.
- “The book that the professor assigned was…” → Should resolve to “difficult,” not “book.”
- Introduction de la mémoire temporelle
- Modélisation d'entrées de longueur variable
- Utilisation de poids partagés entre les pas de temps
- Mais avec les RNN classiques, il y a le problème de la disparition du gradient (vanishing gradient) : l'information s'estompe au fil des séquences longues.
- Ajout de portes (oubli, entrée, sortie) pour réguler le flux d'informations.
- Préservation des dépendances sur des contextes plus longs.
- Considérez les LSTM comme des « filtres intelligents » qui décident quoi retenir, oublier ou transmettre en sortie.
- Transition → Les RNN étaient puissants, mais lents et difficiles à paralléliser. Ils peinaient également à gérer les dépendances à très longue portée, ouvrant ainsi la voie aux Transformers.



De N-grams aux Transformers

4. Transformers (2017–Present): Context Without Recurrence

- Les Transformers ont révolutionné le NLP en remplaçant la récurrence par l'auto-attention — un mécanisme qui permet à chaque mot de prendre en compte tous les autres mots de la phrase pour déterminer ce qui importe le plus.
- *“She dropped the glass because it was fragile.”*
  The model learns that “it” likely refers to “glass,” not “she.”
- Auto-attention : chaque mot génère des vecteurs de requête, de clé et de valeur pour calculer la pertinence.
- Traitement parallèle : contrairement aux RNN, les Transformers traitent des séquences entières simultanément, ce qui permet une accélération considérable.
- Codage positionnel : comme ils ne traitent pas les jetons de manière séquentielle, des informations de position sont ajoutées pour préserver l'ordre.
- Encodeur-décodeur : utilisé en traduction automatique et ayant depuis évolué vers
- Décodeur seul (par ex. GPT)
- Encodeur seul (par ex. BERT)
- Transition → Une fois cette nouvelle architecture établie, la seule voie possible était la montée en puissance : modèles plus vastes, volumes de données accrus et fenêtres de contexte plus étendues.



De N-grams aux Transformers

5. Scaling Transformers (2018–Now): Bigger, Broader, Multimodal

- **Examples**:
- GPT-2/3/4 (OpenAI), PaLM (Google), LLaMA (Meta), Gemini (Google DeepMind), Claude (Anthropic)
- L'importance de l'échelle :
  - Les fenêtres de contexte sont passées de 512 à 1 million de jetons
  - Permet une compréhension à l'échelle du document et la gestion de longues conversations
  - Le nombre de paramètres est passé de quelques millions à plusieurs milliards
  - Favorise un raisonnement plus nuancé, la saisie de modèles abstraits et même l'émergence de nouvelles capacités
- Capacités multimodales :
  - Entraînement sur du texte, des images, du code et de l'audio — et pas seulement sur le langage
  - Permet aux modèles de décrire des images, d'écrire du code et de comprendre des graphiques

Domaines d'application modernes

•**Génération de code et assistance au développement** : Des outils comme Copilot ou Cursor agissent comme des compagnons de programmation capables d'écrire, de déboguer et d'expliquer du code en temps réel.

•**Pipelines RAG (Retrieval-Augmented Generation)** : L'association des LLM à des bases de données externes permet d'interroger des milliers de documents internes en langage naturel pour en extraire des informations précises.

•**Agents autonomes et multi-agents** : Les modèles planifient, utilisent des outils ou des API externes et collaborent pour exécuter des flux de travail complexes sans intervention humaine constante.

•**Traitement intelligent des documents** : Analyse automatisée de contrats, extraction de données financières, vérification de clauses réglementaires ou traitement de factures.

•**Recherche conversationnelle** : Les moteurs de recherche modernes résument et synthétisent le web pour fournir des réponses directes et contextuelles