



Prétraitement de texte (Text preprocessing)

Présentation de problème

- Exemple d'un problème de classification de texte : analyse de sentiment à partir d'un critique de film (movie review)



Exemples



Prétraitement de texte (Text preprocessing)

Présentation

Cette phase consiste à transformer un document texte en une **séquence des tokens**



Text document




Pré-traitement
de texte



token 1 , token 2, , token N

séquence des tokens

Prétraitement de texte (Text preprocessing)



Prétraitement de texte (Text preprocessing)

Tokenisation : De texte vers mots

En anglais :

Texte

Friends, Romans, Countrymen, lend me your ears;



Il y a des ponctuations (virgule, point-virgule) et des espaces entre les mots.



Diviser le texte en se basant sur ponctuations espaces



Mots

Friends Romans Countrymen lend me your ears

En allemand : les choses sont plus compliqués

Parfois, il y a des mots composés sans le moindre séparateur (comme espaces) :

“Rechtsschutzversicherungsgesellschaften”



Ca signifie en anglais:

“insurance companies which provide legal protection”

En japonais : Y a Pas des espaces !!

Butyoucanstillreaditright?

Prétraitement de texte (Text preprocessing)

Tokenisation : De texte vers tokens

Définition

La **tokenisation** est un processus qui divise un texte en séquence de **tokens**

Un **token** est une unité utile pour un traitement sémantique

Un **token** peut être un mot, une phrase, un paragraphe, ...

Exemple 1

Whitespace Tokenizer

Installer le package nltk

pip install nltk

nltk.tokenize.WhitespaceTokenizer

This is Andrew's text, isn't it?

Problème

« it » et « it? » sont deux tokens différents avec le même sens

Prétraitement de texte (Text preprocessing)

Tokenisation : De texte vers mots

code

```
import nltk
text = "This is Andrew's text, isn't it?"

tokenizer = nltk.tokenize.WhitespaceTokenizer()
tokenizer.tokenize(text)

['This', 'is', "Andrew's", 'text,', "isn't", 'it?']
```

Exemple 2

WordPunct Tokenizer

nltk.tokenize.WordPunctTokenizer

Utilise l'expression régulière `\w+|[\^\w\s]+` pour la tokenisation : token est soit une séquence des caractères alphanumériques soit une séquence des caractères autres que alphanumériques ou espaces

This is Andrew ' s text , isn ' t it ?

Problème

« s » , « isn » , « t » ne sont pas des tokens ayant de sens !

Prétraitement de texte (Text preprocessing)

Tokenisation : De texte vers mots

code

```
tokenizer = nltk.tokenize.WordPunctTokenizer()
tokenizer.tokenize(text)

['This', 'is', 'Andrew', "'", 's', 'text', ',', 'isn',
 "'", 't', 'it', '?']
```

Exemple 3 TreeBankWord Tokenizer

nltk.tokenize.TreebankWordTokenizer

This is Andrew 's text , is n't it ?

code

```
tokenizer = nltk.tokenize.TreebankWordTokenizer()
tokenizer.tokenize(text)

['This', 'is', 'Andrew', "'s", 'text', ',', 'is', "'n't",
 'it', '?']
```

Utilise des **expressions régulières** pour la tokenisation comme suit:

- Divise les mots-contractions en deux mots : **can't** (can not) en **ca** et **n't**
- Traite les ponctuations comme des tokens séparés
- Divise quand on rencontre une virgule ou simple apostrophe suivis par des espaces
- Sépare les points qui sont à la fin des lignes.

Problème

« 's » , « n't » ne sont pas des tokens ayant de sens !

Prétraitement de texte (Text preprocessing)

Normalisation de Tokens

On veut souvent designer des mots ayant des formes différentes comme un même token

Stemming

C'est le processus de suppression des suffixes pour avoir une forme racine (root form) d'un mot. Ce mot racine est appelé **stem**.

Exemple

talk, talks → talk

Lemmatisation

Ce processus se base sur le vocabulaire et l'analyse morphologique. Il retourne une forme de base de mot appelée **lem**.

Exemple

wolf, wolves → wolf

Prétraitement de texte (Text preprocessing)

Normalisation de Tokens

Stemming

Implémentation

Nltk.stem.PorterStemmer

Exemples

feet → feet
wolves → wolv

cats → cat
talked → talk

Problème

Ce processus produit des formes irrégulières ou des non-mots

code

```
import nltk
text = "feet cats wolves talked"
tokenizer = nltk.tokenize.TreebankWordTokenizer()
tokens = tokenizer.tokenize(text)

stemmer = nltk.stem.PorterStemmer()
" ".join(stemmer.stem(token) for token in tokens)

u'feet cat wolv talk'
```

Prétraitement de texte (Text preprocessing)

Normalisation de Tokens

Lemmatisation

Implémentation

`nltk.stem.WordNetLemmatizer`

Exemples

feet → foot cats → cat
wolves → wolf talked → talked

Problème

Il y a des formes qui ne sont pas réduites

code

```
import nltk
text = "feet cats wolves talked"
tokenizer = nltk.tokenize.TreebankWordTokenizer()
tokens = tokenizer.tokenize(text)
```

```
stemmer = nltk.stem.WordNetLemmatizer()
" ".join(stemmer.lemmatize(token) for token in tokens)
u'foot cat wolf talked'
```

Prétraitement de texte (Text preprocessing)

Normalisation de Tokens

Reap

- Un texte est une séquence des **tokens**
- **Tokenisation** est un processus d'extraction des tokens
- On peut normaliser les tokens par **Stemming** ou **lemmatisation**