

Atelier 1-Partie 1

Prétraitement du langage naturel

Prétraitement

- Dans cet atelier, nous explorerons comment prétraiter les tweets pour l'analyse des sentiments.
- Utiliser le package [NLTK](<http://www.nltk.org>) pour effectuer un pipeline de prétraitement pour les ensembles de données Twitter.

Introduction

- Vous effectuerez une analyse des sentiments sur les tweets. Pour vous aider, nous utiliserons le package **[Natural Language Toolkit (NLTK)]**(<http://www.nltk.org/howto/twitter.html>), une bibliothèque Python open source pour le traitement du langage naturel.
- Il dispose de modules pour la collecte, la gestion et le traitement des données Twitter.
- Pour cet exercice, nous utiliserons un ensemble de données Twitter fourni avec NLTK : Cet ensemble de données a été annoté manuellement et sert à établir rapidement des références pour les modèles.

```
[ ]
import ..... # Python library for NLP
from nltk.corpus import twitter_samples # sample Twitter dataset from NLTK
import matplotlib.pyplot as plt # library for visualization
import random # pseudo-random number generator
```

À propos de l'ensemble de données Twitter

L'échantillon de données de NLTK est séparé en tweets positifs et négatifs. Il contient exactement 5 000 tweets positifs et 5 000 tweets négatifs.

- Vous pouvez télécharger l'ensemble de données dans votre espace de travail (ou sur votre ordinateur local) en procédant :

```
[ ] # downloads sample twitter dataset.
    nltk.download(.....)
```

- Vous pouvez charger les champs de texte des tweets positifs et négatifs en utilisant la méthode `strings()` du module comme ceci :

```
[ ] # select the set of positive and negative tweets

all_positive_tweets = .....('positive_tweets.json')

all_negative_tweets = .....('negative_tweets.json')
```

- Vous pouvez générer un rapport avec le nombre de tweets positifs et négatifs.

```
[ ] print('Number of positive tweets: ', ..... )
    print('Number of negative tweets: ', ..... )

    print('\nThe type of all_positive_tweets is: ', ..... )
    print('The type of a tweet entry is: ', ..... ))
```

```
➡ Number of positive tweets: 5000
   Number of negative tweets: 5000

The type of all_positive_tweets is: <class 'list'>
The type of a tweet entry is: <class 'str'>
```

- Vous pouvez créer un rapport plus attrayant visuellement en utilisant la bibliothèque [pyplot](<https://matplotlib.org/tutorials/introductory/pyplot.html>) de Matplotlib.

```
▶ # Declare a figure with a custom size
fig = plt.figure(figsize=(5, 5))


# labels for the two classes
labels = .....

# Sizes for each slide
sizes = [len(all_positive_tweets), len(all_negative_tweets)]

# Declare pie chart, where the slices will be ordered and plotted counter-clockwise:
plt.pie(sizes, labels=labels, autopct='%1.1f%%',
        shadow=True, startangle=90)

# Equal aspect ratio ensures that pie is drawn as a circle.
plt.axis('equal')

# Display the chart
.....
```



##Observer des textes bruts

- Avant toute chose, nous pouvons imprimer quelques tweets de l'ensemble de données pour voir à quoi ils ressemblent.
- La compréhension des données est responsable de 80 % du succès ou de l'échec des projets de science des données.
- Ci-dessous, vous imprimerez un tweet positif aléatoire et un tweet négatif aléatoire. Nous avons ajouté une marque de couleur au début de la chaîne pour mieux distinguer les deux.

```
[ ] # print positive in greeen
    print('\033[92m' + all_positive_tweets[random.randint(0,5000)])

    # print negative in red
    print('\033[91m' + all_negative_tweets[random.randint(0,5000)])
```

- Une observation que vous pourriez avoir est la présence d'[émoticônes](<https://en.wikipedia.org/wiki/Emoticon>) et d'URL dans de nombreux tweets. Ces informations vous seront utiles dans les prochaines étapes.